myVLA 实验报告

LIBERO-Spatial：视觉适配、融合深度与推理效率 | 2026 年 11 月 11 日

摘要：汇总六组模型、五个训练阶段的 30 组闭环评估，并补充 GPU 推理实测。10k 步时 V2.2 达到 96% 成功率，预测完整 12 步动作块的中位耗时为 25.21 ms。视觉适配与融合深度存在交互，训练损失不能直接替代闭环评价。

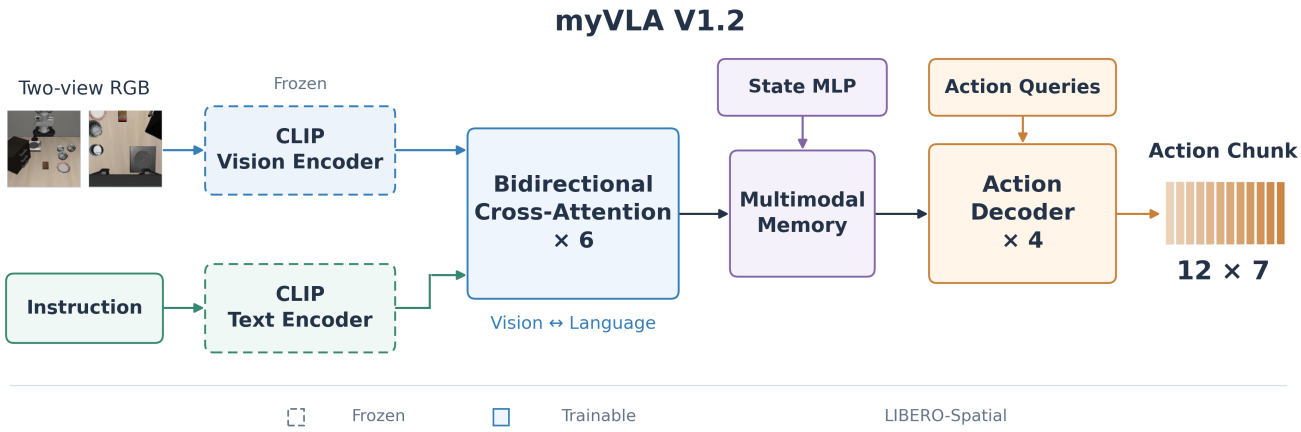


图 1 简洁 VLA 框图，采用工程现有 V1.2 示意图。V2.2 同样使用六层双向融合和四层动作解码器，区别是其视觉编码器参与训练；文本编码器均冻结。状态经 MLP 直接进入多模态 memory，输出为 12×7 动作块。

1 实验设置

项目	设置
数据与评估	10 个任务，500 条演示、62,250 帧，全部用于训练；每检查点 10 任务×10 回合，共 30 组、3,000 回合；相同初始状态索引，seed=42。
训练与模型	CLIP ViT-B/16；224×224 双相机 RGB、语言、8 维状态。隐藏维度 256，动作解码器 4 层；AdamW，动作头 LR=1e-4、视觉 LR=1e-5，预热 500 步，训练 10k 步；FP16、EMA=0.999，有效 batch=64。
软件与硬件	PyTorch 2.6.0、Transformers 4.57.6、NumPy 1.26.4；robosuite 1.4.1、MuJoCo 2.3.7。当前测量机为 i9-12900H、RTX 3060 Laptop GPU（6 GiB），CUDA 构建版本 12.4；历史训练 GPU 未记录。

模型	V1	V1.1	V1.2	V2	V2.1	V2.2
视觉训练	否	否	否	是	是	是
融合层数	0	2	6	0	2	6

表 1 六组实验设计。文本始终冻结；V2.1 实际微批次为 8×8 累积，其余为 16×4。当前八层 V4 和 MetaWorld MT50 尚无完成结果，不参与比较。

2 闭环成功率与训练阶段比较

模型	2k 步	4k 步	6k 步	8k 步	10k 步
V1	2%	76%	89%	81%	84%
V1.1	13%	78%	80%	83%	84%
V1.2	19%	74%	80%	82%	79%
V2	26%	91%	89%	87%	92%
V2.1	18%	70%	88%	86%	85%
V2.2	26%	86%	95%	91%	96%

表 2 每格为 100 回合的成功率，均由原始 progress、汇总及回合日志交叉核验。主要比较统一使用 10k 步，不事后为每组挑选不同预算。

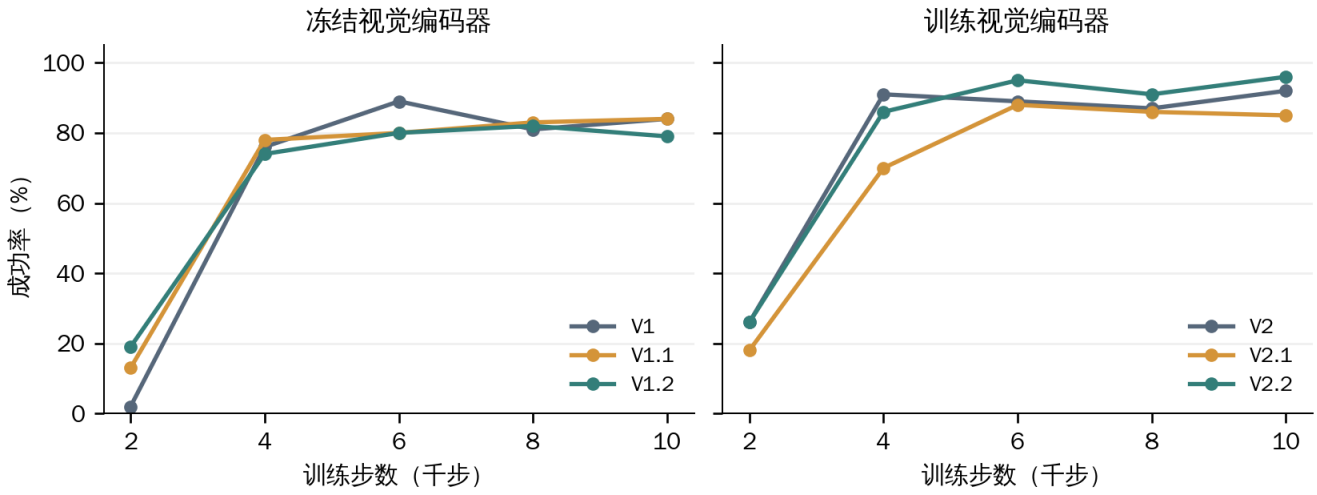


图 2 成功率随训练步数的变化。左侧冻结视觉，右侧训练视觉；同色对应相同融合深度。

2.1 主要结果

训练视觉编码器后，无融合、两层、六层模型的 10k 成功率分别从 84%→92%、84%→85%、79%→96%，提高 8、1、17 个百分点。V2.2 最高，但融合深度并非越大越好：冻结组最终为 84%、84%、79%，训练视觉组为 92%、85%、96%。

V2 在 4k 已达到 91%，而 V2.2 从 6k 起领先。后期表现并不单调：V1 从 6k 的 89% 回落至 10k 的 84%，V2.1 从 88% 回落至 85%。因此，训练更久或损失更低均不保证任务成功率提高。

2.2 差异有多可靠

最终检查点中，V2.2 相对 V1.2 有 19 个配对条件改善、2 个退化（净增 17 点；精确 McNemar 名义 p=0.00022）。相对 V2 则为 7 个改善、3 个退化（+4 点；p=0.344），不足以确立稳健优势。V2.2 的描述性 Wilson 95% 区间为 90.2%—98.4%。检验未校正多重比较，也未考虑任务聚类与训练种子变异。

3 推理效率、拟合损失与逐任务结果

模型	末段损失	峰值显存/GiB	推理中位数/ms	推理 P95/ms
V1	0.1705	0.86	22.41	23.29
V1.1	0.1591	0.99	23.20	24.11
V1.2	0.1553	1.43	24.87	25.76
V2	0.0292	4.87	22.64	23.51
V2.1	0.0290	3.65	23.51	24.51
V2.2	0.0299	5.53	25.21	26.19

表 3 末段损失取最后 20 个唯一日志观测均值，显存为训练日志中的峰值已分配量。推理采用当前 GPU 上的 FP32、EMA、batch=1；每组 3 轮，每轮预热 50 次、计时 200 次，共 600 个有效计时。

3.1 推理时间的含义

计时脚本为 scripts/measure_inference_time.py，使用相同的 21-token 指令、驻留 GPU 的合成观察，并在前后同步 CUDA。包含视觉编码、完整文本编码、动作头和设备端动作解码；排除预处理、分词、输入传输、CPU 输出复制和仿真。文本缓存被绕过，未使用编译或 CUDA Graph，因此不是端到端闭环耗时。

V2.2 为 25.21 ms/动作块，P95=26.19 ms，约 39.7 次预测/秒；相比 V2 增加 2.57 ms（11.4%）。除以 12 得到的 2.10 ms/生成动作只是摊销值，不是单步反应延迟。训练时冻结视觉并不省略推理前向，同结构模型的小差异应结合温度、频率及系统负载波动解释。

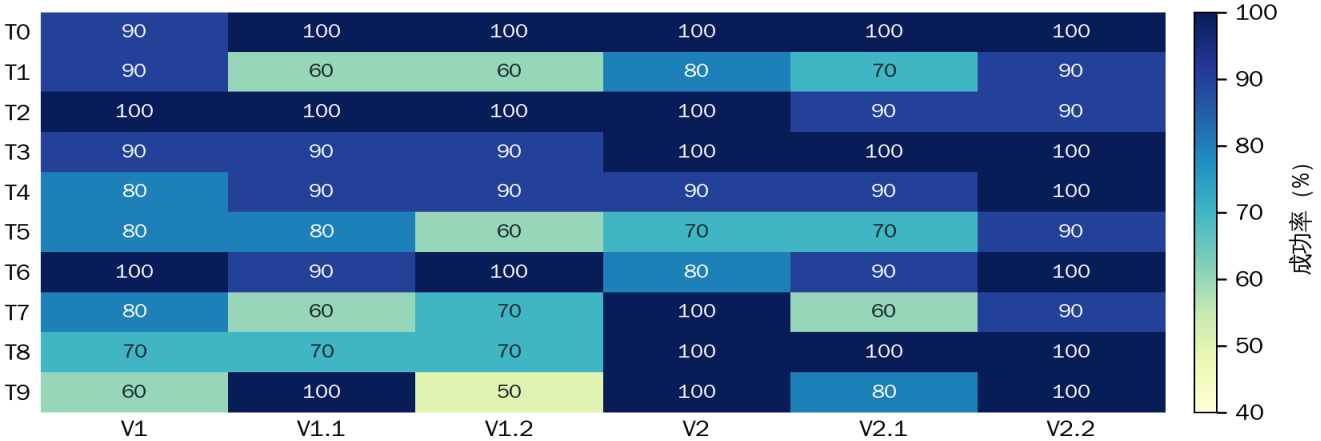


图 3 10k 检查点逐任务成功率，每任务仅 10 回合。T0—T9 的黑碗初始位置依次为：盘子与小碗间、小碗旁、桌面中央、饼干盒上、木柜上层抽屉内、小碗上、饼干盒旁、炉灶上、盘子旁、木柜上。任务均要求将黑碗放到盘子上；小碗对应 ramekin。

V2.2 在六个任务上达到 10/10，在 T1、T2、T5、T7 上各为 9/10。其相对 V1 的明显增益出现在木柜上（60%→100%）和盘子旁（70%→100%）；桌面中央则从 100% 降至 90%。日志没有标注具体失败机制，不能据此认定为抓取滑落或碰撞。

4 结果解释与结论

4.1 视觉适配与融合深度的作用

视觉联合训练将末段损失从约 0.155—0.171 降至 0.029—0.030，并在六层融合组产生最大的成功率提升。合理解释是：动作监督使 CLIP 特征更适合空间几何与控制需求，融合模块也能与视觉特征共同适配。但当前没有特征探针或定位测量，该机制属于待验证假设。

冻结视觉时，加深融合没有带来最终成功率提升；额外容量可能主要改善演示拟合，而未改善闭环决策。V2.1 的损失最低（0.0290）却只有 85% 成功率，V2.2 损失略高（0.0299）却达到 96%，说明不能仅凭训练损失选模型。训练损失来自演示状态和原始参数，闭环结果来自策略实际轨迹与 EMA，两者测量对象不同。

4.2 训练早期偏弱与后期波动

2k 阶段仅为 2%—26%，可能与训练不足及 EMA 滞后有关。衰减 0.999 时，EMA 半衰期约 693 次更新，2,000 次更新后初始化副本仍约占 13.5%。但缺少 raw/EMA 对照，不能隔离其贡献。后期回落也可能来自策略敏感性、演示覆盖不足和有限回合噪声，不能单凭曲线断定过拟合。

4.3 结论的适用范围

每组仅一个记录中的训练种子；30 组结果复用了相同 100 个初始条件，不是 3,000 个独立条件。V1/V1.1 的 6k、8k、10k 共六组旧评估缺完整元数据；其结果与索引可核验，但历史权重选择与全部协议不能独立复原。V2.1 微批次及分段续训也与其他组不同。实验仅覆盖同一 10 任务套件，不能证明未见任务或跨数据集泛化。

结论：在现有记录中，V2.2 以 96% 成功率和 25.21 ms 中位动作块预测耗时取得最好观测表现；相对冻结六层组的 +17 点证据较突出，相对 V2 的 +4 点仍需更多重复验证。下一步优先统一微批次，开展多训练种子与更多初始条件评估，并比较 raw/EMA 和不同动作执行长度。

数据来源与复现

闭环结果：outputs/eval/libero_spatial_v*/ckpt{step}/seed42/ 下的 progress.json、log.json、episodes.jsonl；训练结构与设置：outputs/train/ 下的检查点、清单和训练日志；推理原始记录与汇总：outputs/benchmarks/inference_20261111/。模型按检查点结构识别，历史路径中的两层 v4 对应当前 V2.1，而非八层 V4。本文未重新训练或运行闭环仿真。

参考文献

[1] Radford A, 等. Learning Transferable Visual Models From Natural Language Supervision. ICML, 2021. PMLR 139:8748—8763。

[2] Liu B, 等. LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning. 2023. arXiv:2306.03310。