myVLA 实验研究报告
视觉编码适配与多模态融合的对比分析

LIBERO-Spatial 行为克隆实验 | 中文论文式实验报告
数据与测量截止日期：2026 年 11 月 11 日

摘要：本报告汇总 myVLA 六组模型在五个训练阶段的闭环评估结果，研究视觉编码器是否参与训练、双向视觉—语言融合层深度，以及训练损失与任务成功率之间的关系。数据覆盖 500 条演示、62,250 帧和 30 组评估，共 3,000 个回合。在 10,000 步检查点，六层融合且训练视觉编码器的 V2.2 达到 96% 成功率；冻结视觉的无融合基线为 84%，训练视觉但无融合的 V2 为 92%。另在 RTX 3060 Laptop GPU 上完成 3,600 次推理计时，V2.2 预测完整 12 步动作块的中位耗时为 25.21 ms。结果表明，视觉适配与融合深度存在交互，增加融合层数并不保证性能单调提升。报告同时讨论单一训练种子、有限评估样本、历史环境记录不完整等局限。

1 研究目标与实验分组

本工程使用预训练 CLIP ViT-B/16 编码器 [1] 和可训练动作解码器，开展 LIBERO-Spatial [2] 多任务行为克隆。实验重点是：视觉特征能否通过动作监督进一步适配控制任务；双向交叉注意力的深度是否改善闭环成功率；离线训练损失能否作为模型选择依据。当前实验属于同一套件内的联合多任务学习，不是持续学习或未见任务泛化评估。

模型	视觉编码器	融合层数	总参数量	可训练参数量
V1	冻结	0	154.24 M	4.62 M
V1.1	冻结	2	157.40 M	7.78 M
V1.2	冻结	6	163.72 M	14.10 M
V2	参与训练	0	154.24 M	90.42 M
V2.1	参与训练	2	157.40 M	93.58 M
V2.2	参与训练	6	163.72 M	99.89 M

表 1 六组模型的规范名称与参数规模。模型按检查点中的实际结构识别，不仅按历史文件夹名判断。总参数包含冻结且未用于策略前向的 CLIP 原始投影参数。 [S2、S3]

所有组均冻结文本编码器，使用 4 层动作解码器并输出 12×7 动作。当前 V4 配置为 8 层融合，但没有已完成的闭环评估；工程虽支持 MetaWorld MT50，也没有相应训练与评估结果，因此两者不纳入数值比较。

2 VLA 模型架构框图

图 1 展示当前 LIBERO 策略的完整数据流，以 V2.2 的六层融合为代表。图中维度省略 batch 维。视觉编码器的训练范围和融合层数随表 1 变化，其余主干流程相同。

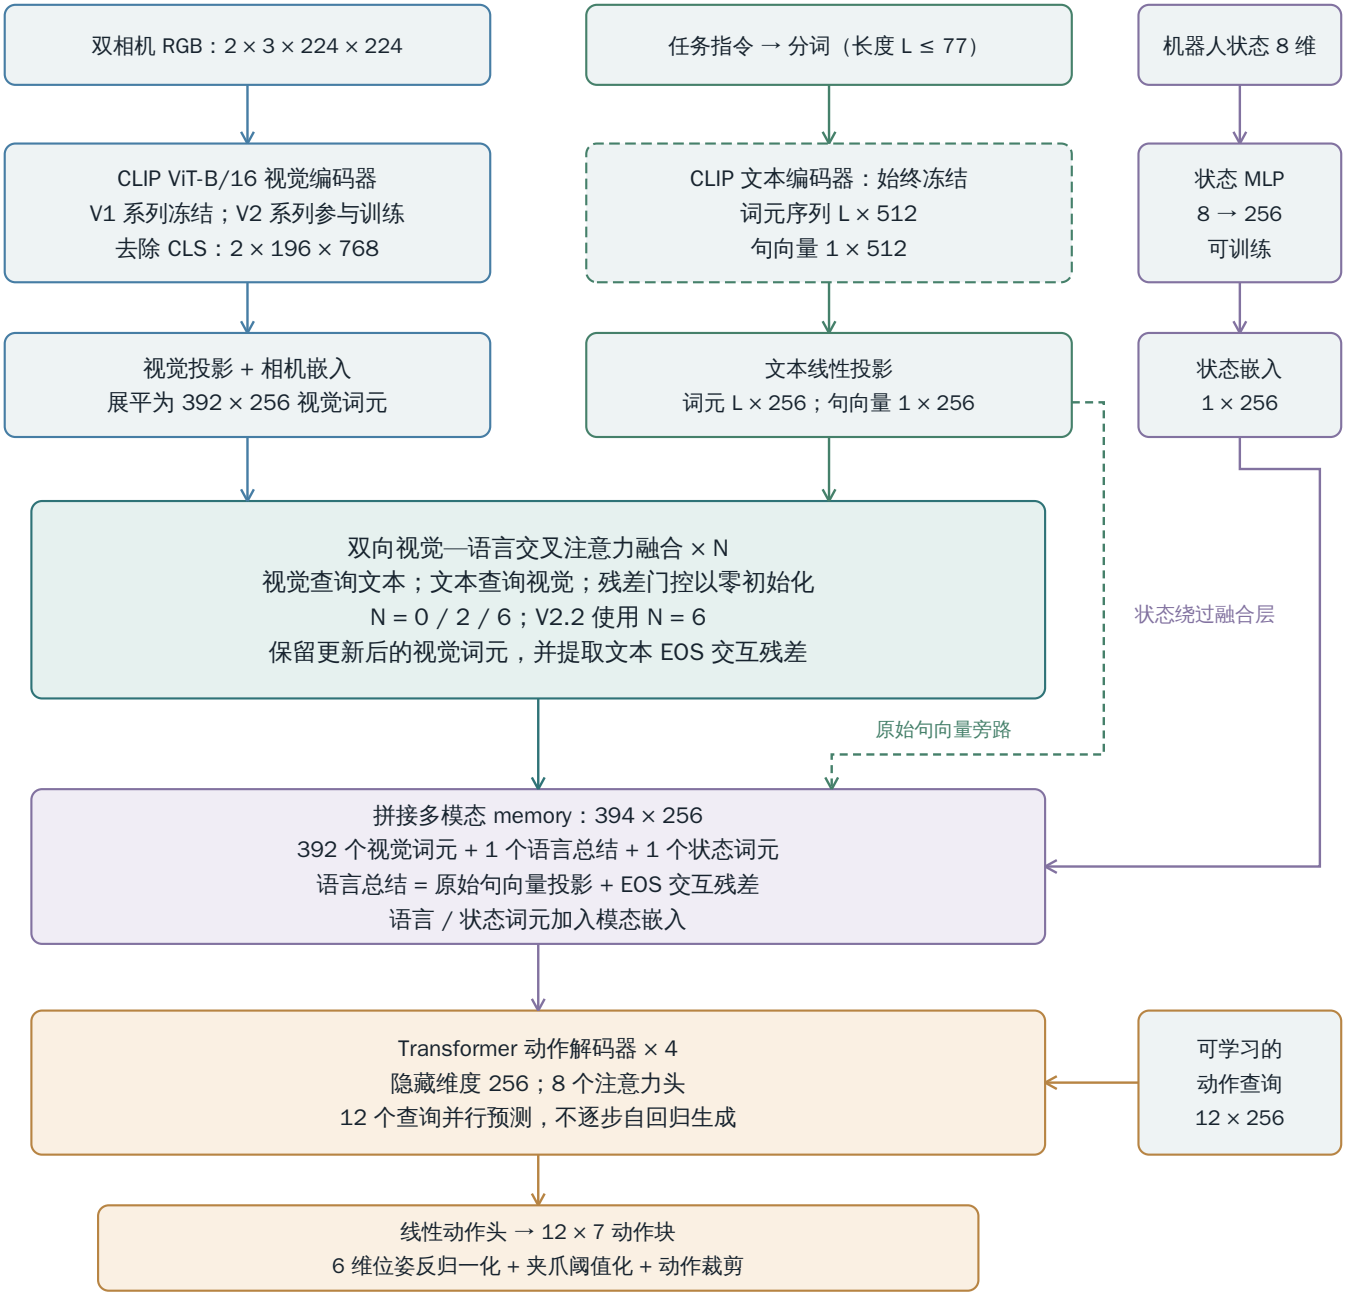


图 1 myVLA 的视觉—语言—动作架构。虚线边框表示始终冻结的文本编码器；绿色虚线路径表示原始句向量的旁路。状态特征直接进入 memory，不经过双向融合。N=0 时跳过融合，语言总结直接使用原始句向量投影；当前八层 V4 尚无已完成评估。框图依据 model.py 与 preprocess.py 绘制。 [S3]

2.1 融合、动作查询与闭环执行

每个相机提供 196 个图像 patch 词元；双相机合计 392 个。融合模块在视觉和文本词元之间交换信息，文本分支的 EOS 交互残差加入原始句向量。随后将视觉词元、语言总结和状态词元拼接为 memory，由 12 个可学习查询并行解码未来动作。模型一次输出完整动作块，评估时顺序执行 12 步，再获取新观察并重新规划。

3 数据集、实现与实验环境

3.1 演示数据及输入预处理

六组检查点的清单均包含相同的 500 条训练轨迹，来自 10 个 LIBERO-Spatial 任务，每任务 50 条演示，共 62,250 帧；清单中全部样本均标记为训练集，未划分演示验证集。采样器按帧有放回均匀采样，因此较长轨迹贡献更多训练样本。10,000 次训练迭代、有效 batch=64，对应 640,000 次帧采样，约为数据规模的 10.28 倍；这不等同于按顺序遍历 10.28 个 epoch。 [S2、S3]

输入包括外部相机与腕部相机 RGB、任务指令，以及 8 维机器人状态：末端位置、轴角姿态和两个夹爪位置。检查到的 HDF5 图像为 128×128；预处理进行垂直翻转、双三次插值至 224×224，再按 CLIP 均值和标准差归一化。状态及连续动作统计量来自训练演示；图像平移与颜色扰动均关闭。 [S2—S4]

组件	版本或配置	证据范围
Python / 工程包	Python 3.10.20；myvla 0.1.0	Python 为当前安装环境；工程包版本来自评估元数据
学习框架	PyTorch 2.6.0；Transformers 4.57.6；NumPy 1.26.4	24/30 组评估头部保留了这些历史版本
仿真环境	robosuite 1.4.1；MuJoCo 2.3.7；相对 OSC_POSE	来自评估元数据；未记录 LIBERO 源码 Git 修订号
CLIP 主干	ViT-B/16；固定修订号 57c21647…e4ae5f3	六组检查点保存的完整修订号一致
当前 CPU / 内存	Intel Core i9-12900H；约 15.35 GiB 内存	报告当天观测值，不能认定为全部历史训练环境
当前 GPU	RTX 3060 Laptop GPU；6,144 MiB	用于新增推理测量；历史训练 GPU 型号未记录
当前系统 / CUDA	Ubuntu 24.04.5 LTS；CUDA 构建版本 12.4；驱动 595.99.02	当前 PyTorch 安装包为 2.6.0+cu124

表 2 软件与硬件环境及其证据来源。区分历史评估元数据与当前主机观测；V2.1 的云端风格路径不能证明其训练 GPU 型号。 [S1、S2、S4]

3.2 共享模型配置

特征投影维度为 256，注意力头数为 8，dropout=0.1。融合块采用双向交叉注意力和零初始化残差门控。解码器共 4 层，输出每步 7 维动作：前 6 维为相对位姿控制，最后 1 维为夹爪 logit。CLIP 原始对比投影层不参与策略前向。 [S2、S3]

4 训练与闭环评估协议

设置	检查点与代码中记录的值
优化器与学习率计划	AdamW；weight decay=0.001；预热 500 步；余弦衰减至峰值学习率的 10%
分组学习率	融合层 / 动作头 1e-4；参与训练的视觉编码器 1e-5
训练预算	10,000 次名义训练迭代；每 2,000 步保存检查点
微批次与累积	五组为 16×4；V2.1 为 8×8；有效 batch 均为 64；2 个数据加载 worker
数值精度与稳定化	FP16 混合精度，参数保持 FP32；梯度缩放；梯度裁剪阈值 1.0
EMA / 随机种子	训练模块 EMA 衰减系数 0.999；训练种子 42
评估条件	10 任务×每任务 10 回合；seed=42；每回合最多 220 个控制步；先稳定 10 步
动作执行方式	一次预测 12 步并依次执行，然后重新观察；每回合重置动作队列

表 3 训练与评估设置。有效 batch 一致并不消除微批次布局造成的数值与采样差异；V2.1 的实际设置以检查点为准。[S1—S3]

4.1 带掩码的行为克隆损失

每个训练帧对应未来 12 步目标动作。轨迹尾部不足 12 步时进行填充，并用掩码排除填充位置。前 6 个归一化连续动作维度采用 Smooth L1 并取维度均值；夹爪采用二元交叉熵 BCE。两项按有效时间步归一化求和：

$$L = \Sigma\, m \cdot [\mathrm{mean}_{j=1\cdots6}\ \mathrm{SmoothL1}(a_j, y_j) + \mathrm{BCE}(g, y_g)] \,/\, \Sigma\, m$$

推理时对连续动作反归一化，将夹爪 logit 以 0 为阈值映射到 −1 或 +1，最后将动作裁剪至 [−1, 1]。训练损失来自演示状态上的局部动作拟合；闭环成功率依赖策略实际访问状态下的整段行为，两者含义不同。[S3]

4.2 成功定义与配对初始条件

若环境成功判定在控制步上限内成立，则该回合记为成功。每任务均有 10 个回合，因此任务成功率的平均值等于全体回合的成功比例。30 组日志的任务 / 回合初始状态索引完全一致，可进行配对对比。3,000 个回合重复使用了 100 个评估条件，不能视为 3,000 个独立测试条件。

4.3 结果核验与统计解释

各组 progress.json 均包含 100 个布尔结果，与 log.json 汇总及 100 条唯一回合记录一致。24 组保留完整元数据，可核实 EMA 及上述协议；V1、V1.1 在 6k / 8k / 10k 的 6 组旧记录缺少完整头部，其结果和初始状态索引可核验，但历史权重选择与全部协议无法由这些文件独立复原。Wilson 95% 区间仅作描述；精确 McNemar 检验是未校正多重比较、未考虑任务聚类和训练种子变异的探索性分析。[S1]

5 总体闭环结果比较

模型	2k 步	4k 步	6k 步	8k 步	10k 步	观测最优值
V1	2%	76%	89%	81%	84%	89%（6k）
V1.1	13%	78%	80%	83%	84%	84%（10k）
V1.2	19%	74%	80%	82%	79%	82%（8k）
V2	26%	91%	89%	87%	92%	92%（10k）
V2.1	18%	70%	88%	86%	85%	88%（6k）
V2.2	26%	86%	95%	91%	96%	96%（10k）

表 4 各训练阶段成功率，每格均为 100 个回合的实际结果。观测最优值是在同一评估集上的事后最大值，不是独立验证结果。主要比较统一使用 10k 检查点。 [S1]

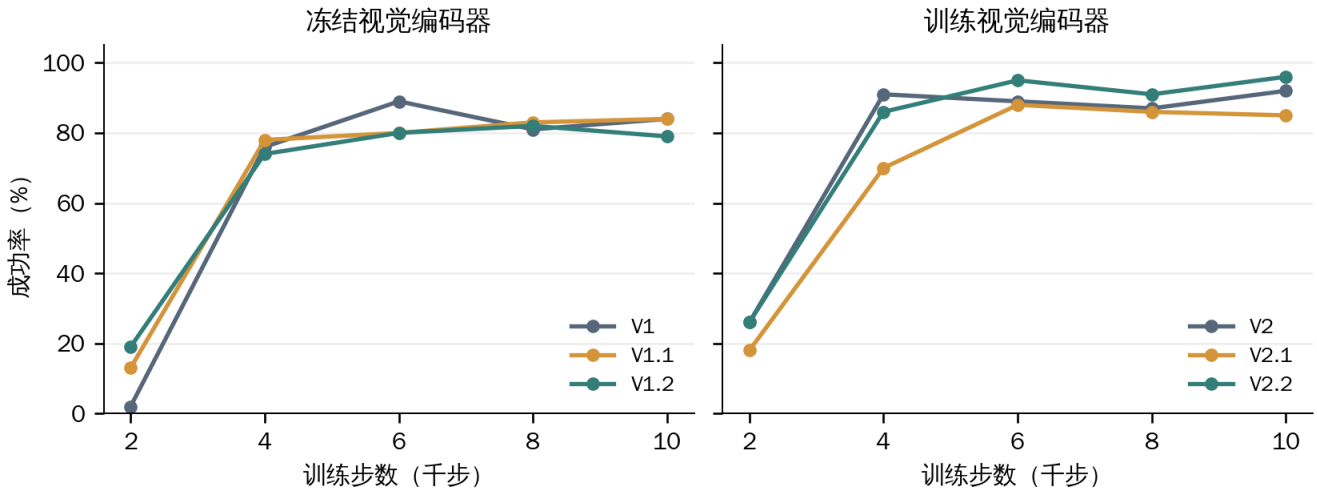


图 2 五个训练阶段的成功率曲线。同一颜色对应相同融合深度，左图冻结视觉编码器，右图训练视觉编码器。 [S1]

5.1 视觉适配与融合深度存在交互

在 10k 检查点，解冻视觉编码器带来的成功率变化分别为：无融合 84%→92%（+8 个百分点）；两层融合 84%→85%（+1）；六层融合 79%→96%（+17）。最大观测增益出现在六层融合与视觉联合训练的组合。V2.2 相比 V2 高 4 个百分点，相比 V2.1 高 11 个百分点，但这些是本次评估中的观测差异，不能直接外推为总体性能差异。

5.2 训练阶段与检查点选择

2k 时各组成功率仅为 2%—26%；4k 时 V2 达到 91%，领先 V2.2 的 86%。从 6k 起，V2.2 依次为 95%、91%、96%，均为当阶段最高值。曲线并不单调：V1 在 6k 达到 89% 后，于 10k 降至 84%；V2.1 从 6k 的 88% 降至 10k 的 85%。

后三个检查点的平均成功率，冻结视觉组为 80.3%—84.7%，训练视觉组为 86.3%—94.0%。这些均值来自同一训练过程中的相关阶段，不能替代多训练种子的重复实验。

6 消融对比与结果不确定性

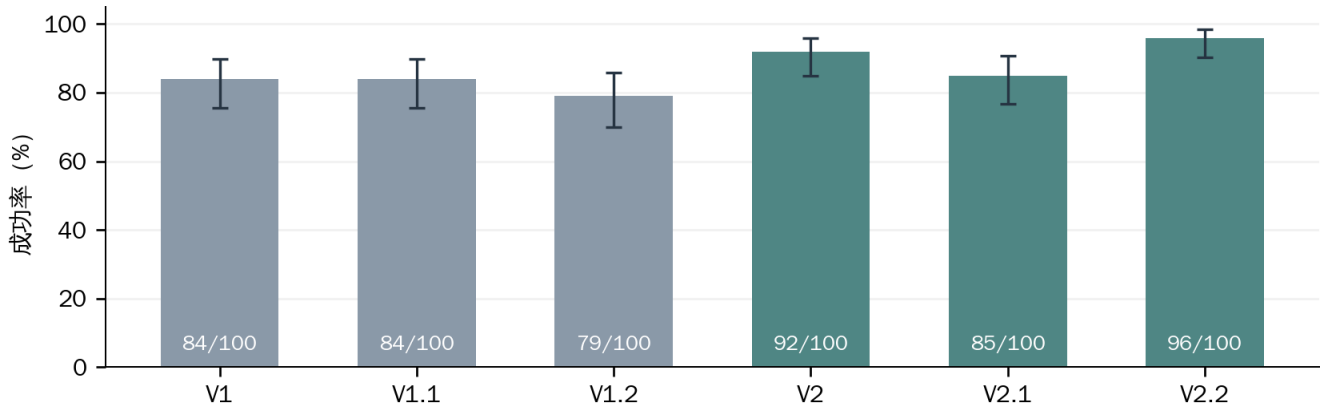


图 3 10k 检查点成功率与描述性 Wilson 95% 区间，每组 n=100。区间描述当前评估条件下的回合结果，不包含独立训练种子之间的波动。 [S1]

对比（B 相对 A）	变化	仅 B 成功	仅 A 成功	精确 p 值
V2 / V1	+8 点	15	7	0.134
V2.1 / V1.1	+1 点	13	12	1.000
V2.2 / V1.2	+17 点	19	2	0.00022
V2.2 / V2	+4 点	7	3	0.344
V2.2 / V2.1	+11 点	14	3	0.013

表 5 最终检查点的配对比较。“仅 B 成功”表示相同初始条件下 B 成功而 A 失败。双侧精确 McNemar p 值仅基于不一致结果对，未做多重比较校正，并依赖回合对独立的假设；实际存在共同任务结构，故只作探索性参考。 [S1]

6.1 哪些结论获得较强的记录内支持

V2.2 相对 V1.2 的证据最突出：19 个条件改善、2 个条件退化，净增 17 个百分点，名义 p=0.00022。这支持在当前架构与数据条件下优先研究视觉联合训练，但结论仍受单一训练种子与任务集合限制。V2.2 相对 V2 的 +4 点则来自 7 个改善和 3 个退化，p=0.344；现有样本不足以确立六层融合相对无融合的可靠优势。

V2.2 的描述性区间为 90.2%—98.4%，V2 为 85.0%—95.9%，V1 为 75.6%—89.9%。区间较宽且部分重叠，每任务只有 10 回合，细粒度排名应谨慎解释。V2.1 另有 8×8 微批次布局和分段续训差异；有效 batch 相同表示预算相近，而不是完全受控的实验。

6.2 统一终点与事后挑选最优点

统一比较 10k 可避免每个模型使用不同训练预算，但报告整体仍是回顾性分析。若各自挑选最佳检查点，V1 为 6k 的 89%，V2.2 为 10k 的 96%，差距为 7 点，小于统一终点时的 12 点。两种选择方式都不能替代在新种子和未使用初始条件上的最终测试；后续应预先规定模型选择规则。

7 逐任务表现与剩余失败

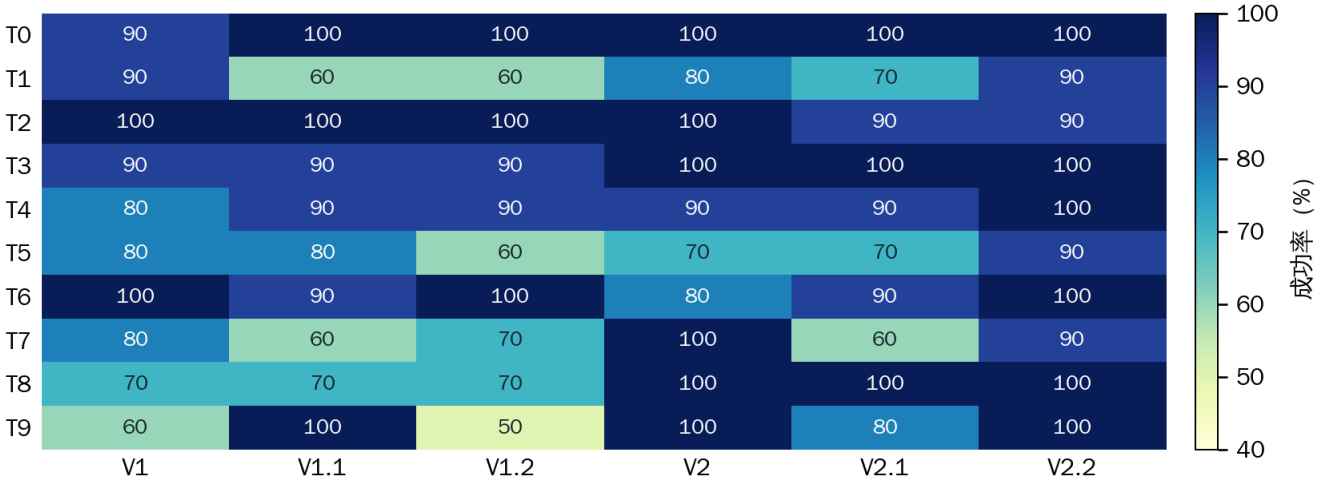


图 4 最终检查点的逐任务成功率。每格只有 10 个回合，故以 10 个百分点为最小变化单位。任务编号与共同回合日志一致。 [S1]

任务	黑碗初始位置	V1	V2	V2.2
T0	盘子与小碗之间	90%	100%	100%
T1	小碗旁	90%	80%	90%
T2	桌面中央	100%	100%	90%
T3	饼干盒上	90%	100%	100%
T4	木柜上层抽屉内	80%	90%	100%
T5	小碗上	80%	70%	90%
T6	饼干盒旁	100%	80%	100%
T7	炉灶上	80%	100%	90%
T8	盘子旁	70%	100%	100%
T9	木柜上	60%	100%	100%

表 6 任务索引与部分模型结果。全部任务均要求抓起黑碗并放到盘子上，变化在于初始空间关系；此处“小碗”对应任务名中的 ramekin。 [S1、S4]

7.1 总体提升来自哪些任务

相对 V1，V2.2 在木柜任务由 60% 提升至 100%，在盘子旁任务由 70% 提升至 100%；小碗旁和饼干盒旁保持相同；桌面中央则由 100% 降至 90%。相对 V2，V2.2 在小碗上、饼干盒旁各增加 20 点，小碗旁和抽屉内各增加 10 点，但在桌面中央和炉灶上各降低 10 点。

V2.2 在六个任务上为 10/10，在其余四个任务上为 9/10；四次失败分别出现在 T1、T2、T5、T7。日志没有将失败标注为抓取滑落、碰撞、定位偏差或放置失败，因此未经轨迹或视频审查，不能把这些机制写为已确认的失败原因。

8 训练优化表现与资源开销

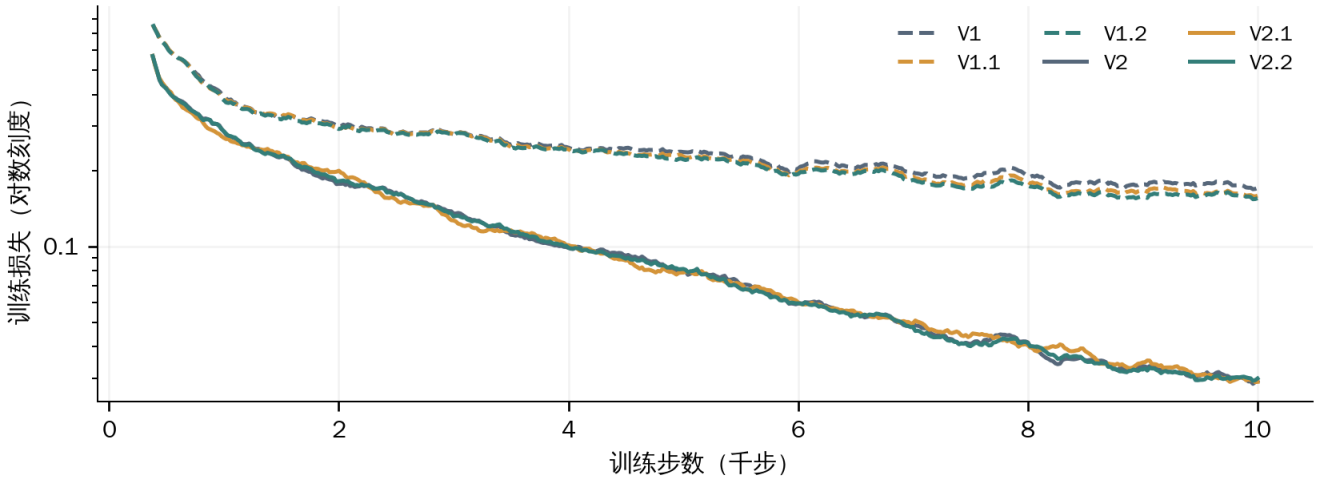


图 5 训练损失曲线。每个点使用最近 20 个日志观测的滑动均值，约覆盖 400 次训练迭代；虚线冻结视觉编码器，实线训练视觉编码器。训练损失来自当前原始参数，而非评估使用的 EMA 参数。 [S2、S3]

模型	末段平均损失	日志峰值显存	日志训练时间
V1	0.1705	0.86 GiB	2.30 小时
V1.1	0.1591	0.99 GiB	2.44 小时
V1.2	0.1553	1.43 GiB	1.53 小时
V2	0.0292	4.87 GiB	3.28 小时
V2.1	0.0290	3.65 GiB	4.92 小时（三段求和）
V2.2	0.0299	5.53 GiB	5.30 小时

表 7 末段损失为最后 20 个唯一步骤日志的均值；显存为日志中的最大已分配 GPU 显存，不是设备总占用。V2.1 将三段续训各自最后的耗时计数相加，其余取最后计数。历史硬件和负载不完整，不能把这些值当作受控速度基准。 [S2]

8.1 更低的训练损失不保证更高的闭环成功率

视觉联合训练的末段损失约为 0.029—0.030，明显低于冻结组的 0.155—0.171。但损失最低的 V2.1（0.0290）仅达 85% 成功率，损失稍高的 V2.2（0.0299）却达 96%。冻结组 V1.2 的拟合损失低于 V1，最终成功率反而较低（79% 对 84%）。因此，训练损失排序不能直接替代闭环表现排序。

损失衡量演示状态上的局部动作误差；成功率是策略实际轨迹上的长时程阈值结果；已记录的评估使用 EMA，而训练曲线来自原始参数。这些目标与测量差异可以解释二者为何不必一致，但不能证明某一次失败一定来自分布偏移。

8.2 容量与开销

可训练参数从 V1 的 4.62 M 增至 V2.2 的 99.89 M；日志峰值显存从 0.86 GiB 增至 5.53 GiB。V2.2 记录训练 5.30 小时，V2 为 3.28 小时；由于历史 GPU 与系统负载未记录，不能据此宣称硬件速度或成本效率的确定差异。

9 GPU 推理耗时实测

9.1 测量协议与计时边界

使用工程原有 scripts/measure_inference_time.py，在 RTX 3060 Laptop GPU（6 GiB）上运行；软件为 PyTorch 2.6.0+cu124、CUDA 构建版本 12.4、驱动 595.99.02。六组均使用 10k EMA 检查点、FP32 参数和计算、batch=1、双相机 224×224 输入、8 维状态，以及相同的 21-token 指令。三轮测量串行执行，各轮以固定日程种子 42 打乱模型顺序；每个进程预热 50 次、计时 200 次，最终每组 600 次，共 3,600 次。先导与已替换诊断运行不计入汇总。 [S6]

使用 CPU 墙钟计时，并在推理前后同步 CUDA。范围包含视觉编码、完整文本编码、动作头及设备端 12×7 动作块解码。固定合成输入已归一化且驻留 GPU，分词在计时前完成；不包含权重加载、图像预处理、输入传输、动作复制回 CPU 或环境执行。使用 eager 推理，未启用编译或 CUDA Graph。脚本刻意绕过实际闭环中的文本缓存，因此这里是“驻留输入、文本未缓存”的推理微基准，不是端到端闭环耗时。

模型	中位数/ms	均值/ms	P95/ms	三轮中位数范围/ms	动作块/秒
V1	22.41	22.49	23.29	22.38—22.45	44.6
V1.1	23.20	23.26	24.11	23.11—23.33	43.1
V1.2	24.87	24.93	25.76	24.72—24.99	40.2
V2	22.64	22.71	23.51	22.49—22.73	44.2
V2.1	23.51	23.59	24.51	23.46—23.57	42.5
V2.2	25.21	25.27	26.19	25.14—25.27	39.7

表 8 2026 年 11 月 11 日新增的 GPU 推理计时。中位数、均值和 P95 均由每组 600 次同步计时合并计算；范围列为三个独立加载进程的中位数最小值至最大值。动作块/秒=1000÷中位耗时。所有输出均有限，形状为 [1,12,7]。 [S6]

9.2 融合深度、延迟与行为表现

V2.2 每次完整预测的中位耗时为 25.21 ms，P95 为 26.19 ms，约为 39.7 个动作块/秒。相对无融合的 V2，中位耗时增加 2.57 ms（11.4%），对应已有闭环结果的 96% 与 92%。两类实验的测量对象不同，不能据此建立可外推的速度—精度前沿。

同一融合深度下，训练时冻结视觉编码器并不会省略推理前向。因此，V1/V2、V1.1/V2.1、V1.2/V2.2 之间的小幅耗时差异，应考虑运行波动，不能直接归因为“冻结带来推理提速”。测量未锁定笔记本温度、GPU 频率和功耗管理，后台显示活动亦未完全控制。

9.3 动作摊销耗时与响应延迟的区别

将 V2.2 的中位耗时摊到 12 个生成动作，约为 2.10 ms/动作，但这只是核算方式：获得一次新观察后的完整预测仍需约 25.21 ms，之后才按队列执行。它既不是单步反应延迟，也不是仿真实际控制频率。部署测量还需覆盖文本缓存路径、预处理、传输、CPU 动作读取和环境执行。

10 结果解释、原因假设与实验局限

10.1 视觉适配为什么可能有效

已观察到：视觉联合训练显著降低行为克隆损失，最终成功率相对对应冻结组增加 8、1、17 个百分点。**可能机制：**动作监督使 CLIP patch 特征更适合任务相关的空间几何、接触线索和相机外观。V1.2→V2.2 的大幅提升与这一解释相符，但当前并未直接测量特征质量；仍需表征探针、定位指标和多种子消融验证，不能将其写为已证实的因果机制。

10.2 为什么融合层更多并不总是更好

已观察到：冻结视觉时，0/2/6 层融合的最终成功率为 84%、84%、79%；训练视觉时为 92%、85%、96%。**可能机制：**融合模块需要视觉特征与控制目标共同适配；视觉固定时，额外容量可能主要改善演示拟合，而未改善闭环决策所需的空间信息。优化敏感性和有限样本波动也是替代解释；不能得出“增加深度必然提升性能”的结论。

10.3 早期表现弱和后期曲线波动的可能原因

已观察到：2k 时仅 2%—26%，4k 明显提升，后期部分检查点又出现回落。**可能机制：**早期训练不足与 EMA 滞后共同影响结果。固定衰减 0.999 时，EMA 半衰期约 693 次更新；经过 2,000 次成功更新后，初始化参数副本仍约占 13.5% 权重。这说明滞后具有机制上的可能性，但当前没有 raw/EMA 对比评估，无法隔离其贡献。后期回落还可能来自策略敏感性、演示覆盖不足或小样本噪声，不能仅凭曲线认定过拟合。［S3］

10.4 因果解释和泛化结论的边界

每组只有一个记录中的训练种子，各检查点重复使用同样 100 个初始条件；回合按任务聚类，回顾性多重比较存在选择偏差。V1/V1.1 的六组旧评估缺完整元数据；V2.1 微批次不同且有三段训练日志，历史输出路径也变化。实验仅覆盖同一 10 任务套件，不能证明未见指令泛化或跨套件、跨 MT50 迁移。文档提到的历史验证集划分变更缺少可匹配归档对照，故本报告不为其赋予数值收益。

10.5 建议的后续验证

首先，对“视觉是否训练×0/2/6 层融合”的 2×3 设计进行至少三个独立训练种子重复，并统一微批次、预先规定最终模型选择规则。其次，扩大初始条件覆盖并采用考虑任务层次的不确定性估计。第三，在 2k/4k 对比 raw 与 EMA，检验滞后假设。第四，固定同一训练策略，比较执行 1/4/8/12 步后的重新规划效果。最后，用视频标注失败类型，再单独评估八层 V4 与其他套件。这些均为待开展实验，不计作已完成结果。

11 结论与数据可追溯性

当前记录支持优先研究视觉编码适配，并表明其效果受融合深度影响。统一 10k 预算下，V2.2 是观测最优模型，在 100 个 LIBERO-Spatial 回合中达到 96%：比六层冻结组高 17 点，比无融合冻结基线高 12 点，比无融合训练视觉的 V2 高 4 点。最后这一差距相对样本规模较小，尚不能认定为稳健优势。训练损失可用于监控优化，但比较控制性能仍需闭环评估。

新增 GPU 实测中，V2.2 的动作块预测中位耗时为 25.21 ms，P95 为 26.19 ms。该测量包含完整文本编码，排除预处理、传输和仿真，不能替代实际控制链路时延。本报告对已有训练与闭环数据重新统计，并新增推理微基准；没有重新训练或重新运行闭环仿真。

11.1 项目证据索引

编号	相对项目根目录的证据	报告用途
S1	outputs/eval/libero_spatial_v*/ ckpt{step}/seed42/ 下的 progress.json、log.json、episodes.jsonl	30 组评估；总体和逐任务结果；初始条件配对；元数据覆盖
S2	outputs/train/libero_spatial_v*/ 下的 checkpoint_{step}.pt、manifest.json、metrics.jsonl 或 log.jsonl	模型结构、实际训练设置、演示规模和损失 / 时间 / 显存日志
S3	src/myvla/ 下的 model.py、data.py、preprocess.py、train.py、evaluate.py、ema.py	模型前向、采样、损失、动作解码、闭环协议与 EMA
S4	data/libero_spatial/*_demo.hdf5；pyproject.toml；当前软件环境清单	图像样例结构、依赖规格和当前环境版本
S5	configs/train_cfg_v4.yaml；README.md；项目模型版本记录文档	未评估八层配置与历史说明；不替代原始结果
S6	scripts/measure_inference_time.py；outputs/benchmarks/inference_20261111/	18 份有效计时 JSON、测量清单、summary.json 与 summary.csv

表 9 v* 对应 v1、v1_1、v1_2、v2、v2_1、v2_2；step 对应 2000、4000、6000、8000、10000。报告版本用小数点，文件路径用下划线。

11.2 复现信息与尚未补全的记录

CLIP 固定修订号为 57c216476eefef5ab752ec549e440a49ae4ae5f3。历史云端路径中的“两层可训练视觉 v4”对应当前 V2.1，并非当前八层 V4。六组清单的轨迹身份与长度一致，但路径和时间戳不等同于所有 HDF5 的加密哈希。历史训练 GPU / 驱动与 LIBERO Git 修订号仍缺记录。所有统计与新增测量截止 2026 年 11 月 11 日。

参考文献

[1] Radford A, 等. Learning Transferable Visual Models From Natural Language Supervision. ICML, PMLR 139:8748—8763, 2021. proceedings.mlr.press/v139/radford21a.html。

[2] Liu B, 等. LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning. 2023. arXiv:2306.03310。文献用于说明主干与基准背景，本报告未与其公开基线成绩作直接比较。